

Exploración activa autónoma usando ROS2 y Aprendizaje por Refuerzo

Arambarri-Calvo, Javier¹; Fernandez-Fernandez, Raul^{2*}; Chacón, Jesús²

¹ Dto. Ingeniería de Sistemas y Automática, Escuela de Ingeniería de Bilbao, Universidad del País Vasco (EHU), Bilbao, España.

² Dto. Arquitectura de Computadores y Automática, Universidad Complutense de Madrid (UCM), Madrid, España.

* Email para correspondencia: raufer06@ucm.es


PROBLEMÁTICA & OBJETIVO

La navegación autónoma en entornos desconocidos exige estimar simultáneamente la posición del robot y construir un mapa del entorno (SLAM). Frente a los enfoques reactivos tradicionales, el **Active SLAM** (A-SLAM) incorpora la planificación de acciones para reducir la incertidumbre durante la exploración.

Se propone un sistema basado en **Deep Reinforcement Learning** (DRL) que permite aprender políticas de exploración que consideren el impacto futuro de las acciones. Se utiliza el algoritmo **TD3** y redes convolucionales (**CNN**) y perceptrón multicapa (**MLP**) para procesar información sensorial de alta dimensionalidad.

El sistema se implementa en **ROS2** y su objetivo es gobernar autónomamente un robot diferencial para explorar entornos desconocidos maximizando la completitud del mapa mediante el aprendizaje de políticas de navegación.

ESQUEMA PROPUESTO



MÉTODO PROPUESTO

Markov Process Decision (MDP): toma de decisiones secuenciales


ACCIONES

$$v_t = [-1, 1]$$

$$w_t = [-1, 1] \text{ rad/s}$$

Velocidad lineal, que se proyecta a $[0, 0.3]$ m/s y velocidad angular.

ESTADO $S_t = [L_t, M_t^{LEM}, M_t^{GEM}, \sin(\Psi_t), \cos(\Psi_t), v_{t-1}, w_{t-1}]$



LEM: mapa ocupación local centrado en el robot (egocéntrico).

GEM: mapa exploración global con posición del robot

LiDAR 500 mediciones en 360°, representación dual del mapa, orientación en componentes trigonométricas sin discontinuidades y acciones previas.

CNNs

CNN LiDAR (1D)	CNN Mapas (2D)
Conv1d(1,16, k=7, s=3)	Conv2d(2,16, k=3, s=2, p=1)
ReLU()	ReLU()
Conv1d(16,1, k=6, s=1, p=1)	Conv2d(16,2, k=2, s=2, p=1)
ReLU()	ReLU()
AdaptiveMaxPool1d(20)	AdaptiveMaxPool2d((5,5))
Flatten()	Flatten()

RECOMPENSA $R_t = \frac{r_{ctrl} + r_{obs} + r_{expl} + r_{time}}{1000} + R_{term}$


Movimiento y control: rango operativo seguro de velocidades lineal y angular.

Esquivación de obstáculos: penaliza si supera un umbral de distancia mínima en cualquier dirección.

% de la exploración mediante MSE.

Eventos terminales: exploración completada (>95%), colisión o timeout.

ARQUITECTURA ROS2



CONCLUSIONES

Eficacia del algoritmo TD3 de DRL para abordar el problema del A-SLAM con redes CNN y MLP: la curva naranja muestra el aumento del % explorado a lo largo del entrenamiento.

Las trayectorias oscilantes descubren que la recompensa asociada a la velocidad angular no está influyendo lo deseado, por lo que es necesario un **análisis de la pérdida del crítico** del algoritmo TD3 mediante **MSBE** (Mean Square Bellman Error) para reescalar la recompensa.

RESULTADOS 77'8%

de episodios exitosos (exploración > 95%) en 500 episodios de inferencia, pero con trayectorias oscilantes.

