

Exploración activa autónoma usando ROS2 y Aprendizaje por Refuerzo

Arambarri-Calvo, Javier¹; Fernandez-Fernandez, Raul²; Chacón, Jesús²

2



UNIVERSIDAD
COMPLUTENSE
MADRID

1



BILBOKO
INGENIARITZA
ESKOLA
ESCUELA
DE INGENIERÍA
DE BILBAO



XLVII Jornadas de Automática – Córdoba - 03/09/2026

ÍNDICE



BILBOKO
INGENIARITZA
ESKOLA
ESCUELA
DE INGENIERÍA
DE BILBAO

1. Introducción y motivación
2. Estado del arte
3. Método propuesto
4. Experimentación y resultados
5. Conclusiones y trabajos futuros

ÍNDICE



BILBOKO
INGENIARITZA
ESKOLA
ESCUELA
DE INGENIERÍA
DE BILBAO

1. Introducción y motivación

2. Estado del arte

3. Método propuesto

4. Experimentación y resultados

5. Conclusiones y trabajos futuros

1. Introducción y motivación

El desafío de la exploración autónoma: el mundo de Pepelu.

Sin *GPS* ni mapas previos.

Su misión es doble y contradictoria: **construir un mapa** del lugar mientras **descubre dónde está** él mismo.

¡SLAM! – *Simultaneous Localization and Mapping* –

Técnica “pasiva”: ignora cómo su movimiento afecta a la exploración
Solo procesa los datos sensoriales.

¿Cómo sabe a dónde navegar
para explorar?



1. Introducción y motivación

El desafío de la exploración autónoma: el mundo de Pepelu.

Sin *GPS* ni mapas previos.

Su misión es doble y contradictoria: **construir un mapa** del lugar mientras **descubre dónde está** él mismo.




¡**SLAM!** – *Simultaneous Localization and Mapping* –

Técnica “**pasiva**”: ignora cómo su movimiento afecta a la exploración.
Solo procesa los datos sensoriales.

¿Cómo sabe a dónde navegar para explorar?

¡Con métodos reactivos voy hacia las **FRONTERAS!**



1. Introducción y motivación


El desafío de la exploración autónoma

SLAM y FRONTERAS

“...una persona perezosa encontrará una forma fácil de hacerlo” – Bill Gates

Pero desconozco la incertidumbre futura y el valor de mis posibles movimientos, ¡qué pereza!

¡voy a usar *SLAM* Activo o **A-SLAM**!: integrar la toma de decisiones en el proceso de estimación de *SLAM*.



1. Introducción y motivación

El desafío de la exploración autónoma


A-SLAM – *Active Simultaneous Localization and Mapping* –

Proceso secuencial y dependiente del estado del mapa y la localización...

...Aprendizaje por Refuerzo –*Reinforcement Learning*– (RL)

...Aprendizaje por Refuerzo Profundo –*Deep RL*– (DRL)

Y así tomaré unas acciones de control u otras según el estado del mapa... ¡Es genial!



ÍNDICE



BILBOKO
INGENIARITZA
ESKOLA
ESCUELA
DE INGENIERÍA
DE BILBAO


1. Introducción y motivación
2. Estado del arte
3. Método propuesto
4. Experimentación y resultados
5. Conclusiones y trabajos futuros

2. Estado del arte

Aprendiendo a elegir metas

- Uso de RL (algoritmos A3C, DQN) para seleccionar fronteras objetivo.
- Recompensas basadas en ganancia de información o entropía.
- Navegación local clásica.


Niroui, F., Zhang, K., Kashino, Z., Nejat, G., 2019. Deep reinforcement learning robot for search and rescue applications: Exploration in unknown cluttered environments. *IEEE Robotics and Automation Letters* 4 (2), 610–617. DOI: 10.1109/LRA.2019.2891991



Aprendiendo a navegar

- Selección heurística de fronteras.
- Algoritmo TD3 de RL políticas de control con acciones continuas.
- Recompensa compleja: completitud del mapa, reducción de incertidumbre.
- Representaciones multicanal del estado: maldición de la dimensionalidad y CNN.

Cimurs, R., Suh, I. H., Lee, J. H., 2021. Goal-driven autonomous exploration through deep reinforcement learning. URL: <https://arxiv.org/abs/2103.07119>



Zhao, S., et. al., 2024. Exploration- and exploitation-driven deep deterministic policy gradient for active slam in unknown indoor environments. DOI: 10.3390/electronics13050999


Alcalde, M., et. al., 2022. Daslam: Deep active slam based on deep reinforcement learning. DOI: 10.1109/LARS/SBR/WRE56824.2022.9996006

Li, Z., et. al., 2023. Autonomous exploration and mapping for mobile robots via cumulative curriculum reinforcement learning. URL: <https://arxiv.org/abs/2302.13025>

ÍNDICE

1. Introducción y motivación
2. Estado del arte
3. Método propuesto
4. Experimentación y resultados
5. Conclusiones y trabajos futuros

3. Método propuesto



Aprendizaje por Refuerzo Q-learning: aprender el **retorno esperado** o valores q (suma de recompensas futuras acumuladas y descontadas).

$$q^*(s, a) = \mathbb{E}[R_{t+1} + \gamma \max_{a'} q^*(S_{t+1}, a') \mid S_t = s, A_t = a]$$

El operador **máx** j es **irrealizable** es espacios continuos (infinitas acciones posibles).

Arquitectura neuronal Actor-Crítico:

- Actor** π_ϕ : aprende la política de control. Estados del entorno $\rightarrow$ acciones óptimas. **Sustituye al operador máx.**
- Crítico** Q_θ : estima q^* . Evalúa las acciones propuestas por el actor.

$$y = R_{t+1} + \gamma Q_\theta(S_{t+1}, \pi_\phi(S_{t+1}))$$

Salida del actor
(acciones)

3. Método propuesto

Estado del entorno

$$S_t = [L_t, M_t^{LEM}, M_t^{GEM}, \sin(\psi_t), \cos(\psi_t), v_{t-1}, \omega_{t-1}]$$

- L_t : 500 puntos **LiDAR** 360°.
- M_t^{LEM} : mapa egocéntrico local de **ocupación** 24x24 píxeles.
- M_t^{GEM} : mapa de **exploración** global 24x24 píxeles.
- $\sin \psi_t$, $\cos \psi_t$: **orientación** del robot sin discontinuidades.
- v_{t-1}, ω_{t-1} : **acciones** del paso anterior.

Dimensionalidad: **¡¡1656 elementos!!**

Espacio de acciones: continuo



$$a_t = [v_t, \omega_t]$$

- $v_t \in [-1, 1]$: velocidad lineal, interpolada al rango físico real $[0, 0'3]$ m/s.
- $\omega_t \in [-1, 1]$: velocidad angular, concuerda con el rango físico, en rad/s.


Dimensionalidad: **2 elementos**

3. Método propuesto

Estado del entorno: representación dual del mapa



(a) $s = 1$.



(e) $s = 3,5$.

(f) $s = 5$.

- M_t^{LEM} : mapa egocéntrico local (LEM)


Región del mapa original, centrada en el robot, reducida a dimensión 24x24 píxeles mediante *max pooling*.

Factor de escala $s > 1$ para capturar más o menos información del mapa original.

0: libre; 128: desconocido; 255: ocupado

3. Método propuesto


Estado del entorno: representación dual del mapa



- M_t^{GEM} : mapa global de exploración (*GEM*)
Rectángulo mínimo de la región ya explorada del mapa original, reducida a dimensión 24x24 mediante *nearest neighbor*.


La posición del robot se marca con el valor 128 de 3x3 píxeles.

0: inexplorado o desconocido; 255: conocido (libre + ocupado).



3. Método propuesto

Reducción de la dimensionalidad y Algoritmo TD3



3. Método propuesto

Función de recompensa multiobjetivo

$$R_t = \frac{r_{ctrl} + r_{obs} + r_{expl} + r_{time}}{k_s} + R_{term}$$

Control

$$r_{ctrl} = r_{\omega} + r_v \quad \begin{aligned} r_{\omega} &= -k_{\omega} \cdot \omega_t^2, \\ r_v &= -k_v \cdot [10,0 \cdot (v_{target} - v_t)]^2 \end{aligned}$$

% Exploración

$$\Delta \rho^2 = (\rho_t - \rho_{t-1})^2 \quad r_{expl} = \begin{cases} \min(k_{e1} \cdot \Delta \rho^2, 1, 0) \cdot k_{e2} & \text{si } \Delta \rho^2 > 0 \\ -k_{e3} & \text{en otro caso} \end{cases}$$

Seguridad

$$r_{obs} = \begin{cases} -20,0 & \text{si } d_{min} < 0,22 \\ 0,0 & \text{en otro caso} \end{cases}$$

Tiempo

$$r_{time} = -k_t$$


Eventos terminales

$$R_{term} = \begin{cases} +5,0 & \text{si éxito } (\rho \geq 95\%) \\ -2,0 & \text{si colisión o vuelco} \\ -1,0 & \text{si tiempo agotado } (timeout = 40 \text{ s}) \end{cases}$$

3. Método propuesto

Arquitectura ROS2


Simulación



ROS2 Humble
Gazebo Classic

Nodos
Temas (topics)
Servicios
Procesos internos

Robot físico real



ÍNDICE



BILBOKO
INGENIARITZA
ESKOLA
ESCUELA
DE INGENIERÍA
DE BILBAO

1. Introducción y motivación
2. Estado del arte
3. Método propuesto
4. Experimentación y resultados
5. Conclusiones y trabajos futuros

4. Experimentación y resultados


Función de recompensa

Constante	Agente 1	Agente 2	Agente 3
k_s	1000,0	1000,0	1,0
k_w	2,0	3,0	0,3
k_v	2,0	3,0	0,3
k_{e1}	10,0	5,0	5,0
k_{e2}	100,0	100,0	0,5
k_{e3}	0,5	0,5	0,05
k_t	1,0	0,002	0,002

Resultado	Agente 1	Agente 2	Agente 3
Episodios con éxito	61,18 %	77,8 %	87,20 %
Episodios con colisión	37,79 %	21,0 %	12,80 %
Episodios con <i>timeout</i>	1,03 %	1,2 %	0,0 %

Agente 2



Trayectorias oscilantes...



**¡NO SE RESPETA LA
PENALIZACIÓN DE LA
VELOCIDAD ANGULAR!**

4. Experimentación y resultados

Resultados del entrenamiento del Agente 2



[0,075; 0,15]

Error de estimación o resolución
numérica con *MSBE* (Mean
Squared Bellman Error):



$$\sqrt{0,15} \approx 0,387$$

$$\dot{r}_\omega \ll MSBE?$$

r_ω dividido por $k_s = 1000$, por lo
que es del orden de
 10^{-3} ; (0,001).


$$10^{-3} \ll 0,387$$

**ENMASCARADA POR EL
RUIDO DE APROXIMACIÓN**




4. Experimentación y resultados

Resultados del Agente 3



Reajuste de los pesos:


incentivos en el orden de magnitud de 10^{-1} , garantizando que la señal sea comparable a la precisión de la red.




4. Experimentación y resultados

Despliegue del Agente 3 en diferentes entornos

Aunque mantiene la tendencia a dirigirse hacia regiones inexploradas, las diferencias en la representación del entorno entre escenarios limitan su capacidad de generalización y su rendimiento.




(a) 6×6 m.






(b) 10×10 m.

4. Experimentación y resultados

Despliegue en el robot real




Malformación de mapas: plano de exploración del LiDAR y el plano del suelo no son perfectamente paralelos, para distancias elevadas las medidas del sensor pueden sobrepasar las paredes artificiales del escenario y registrar puntos situados fuera de los límites previstos.






4. Experimentación y resultados

Despliegue en el robot real



Movimientos seguros: no colisiona :)



ÍNDICE

1. Introducción y motivación
2. Estado del arte
3. Método propuesto
4. Experimentación y resultados
5. Conclusiones y trabajos futuros

5. Conclusiones y trab. futuros



BILBOKO
INGENIARITZA
ESKOLA
ESCUELA
DE INGENIERÍA
DE BILBAO

Conclusiones

- Eficacia del método propuesto afrontar el problema del A-SLAM:
 - Reducción de la dimensionalidad con CNN 1D y 2D.
 - Éxito al desplegar el agente sobre el escenario entrenado.
 - El robot físico real no colisiona.
- Diferencias espaciales entre los entornos limitan la capacidad de generalización.

Trabajos futuros

- Corregir las trayectorias oscilantes del Agente 2: ¡HECHO! ¿futura publicación?
- Mejorar la **generalización** aplicando **curriculum** al entrenamiento: aumentar progresivamente la dificultad y variando entre escenarios.

Li, Z., et. al., 2023. Autonomous exploration and mapping for mobile robots via cumulative curriculum reinforcement learning. URL: <https://arxiv.org/abs/2302.13025>

Exploración activa autónoma usando ROS2 y Aprendizaje por Refuerzo

Arambarri-Calvo, Javier¹; Fernandez-Fernandez, Raul²; Chacón, Jesús²

2



UNIVERSIDAD
COMPLUTENSE
MADRID

1



BILBOKO
INGENIARITZA
ESKOLA
ESCUELA
DE INGENIERÍA
DE BILBAO



XLVII Jornadas de Automática – Córdoba - 03/09/2026